

MOON CAKE

Melhorando o desempenho de preditores para detecção de transações fraudulentas

intro

Problemas encontrados:

- Disponibilidade de datasets públicos;
- Class Imbalance;
- Falsos Negativos & Overfitting.

intro


Objetivos propostos:

- Entender datasets relacionados à fraudes;
- Construir preditores;
- Otimizar seus desempenhos.

fraudes

“Caracteriza-se como fraude todo ato ardiloso, enganoso e de má fé que possui como objetivo lesar ou ludibriar outrem.”

**Lei Federal N 8.137 - 27 de dezembro de
1990.**



antifraudes

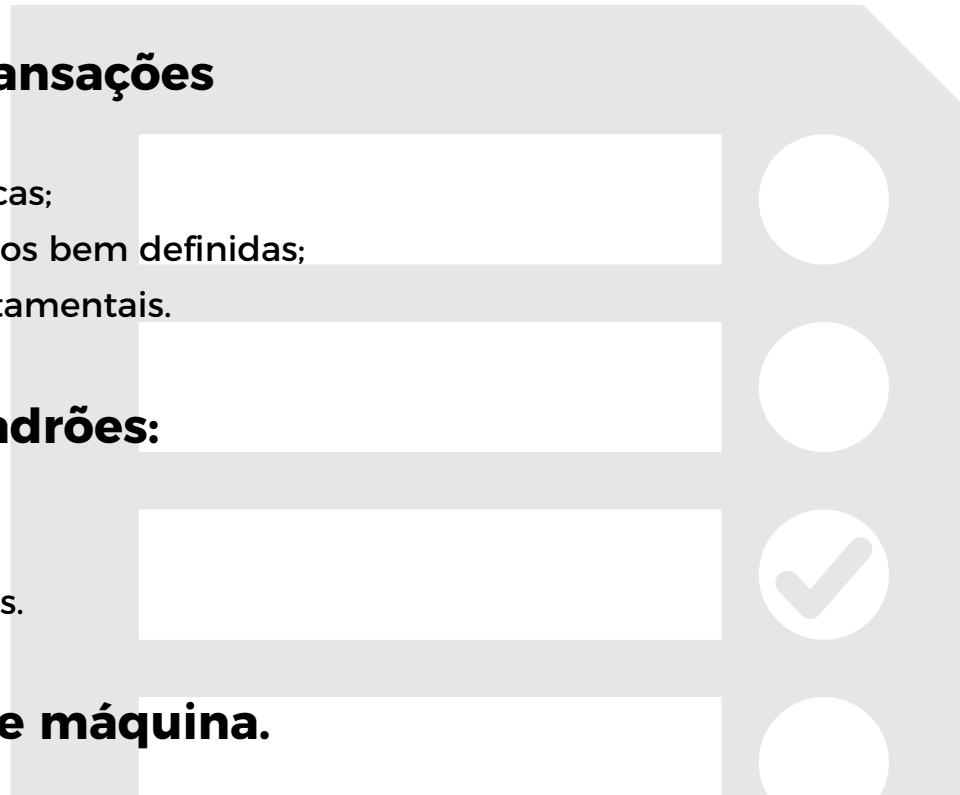
Deteção de transações fraudulentas:

- Análises estatísticas;
- Regras de negócios bem definidas;
- Análises comportamentais.

Deteção de padrões:

- Geográficos;
- Monetários;
- Comportamentais.

Aprendizado de máquina.



algoritmos

Modelos Preditivos:

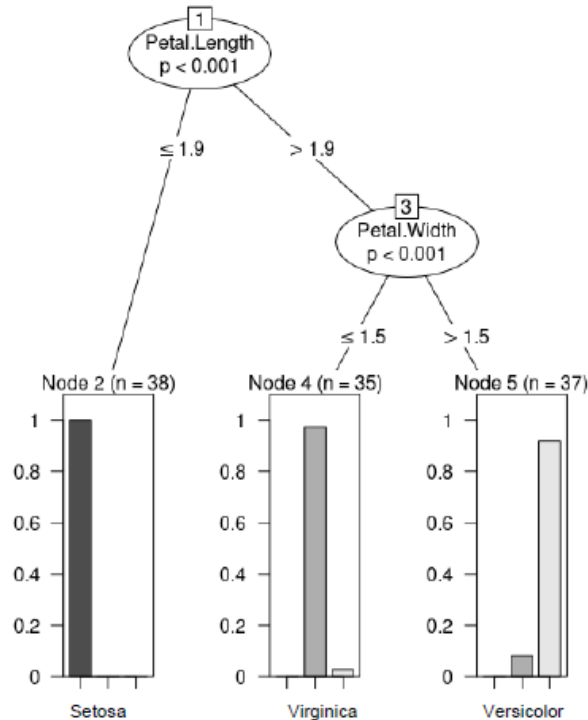
- Tree Classifiers;
- Random Forests;
- SVM (Support Vector Machines).

Sampling:

- ROS/RUS;
- SMOTe.



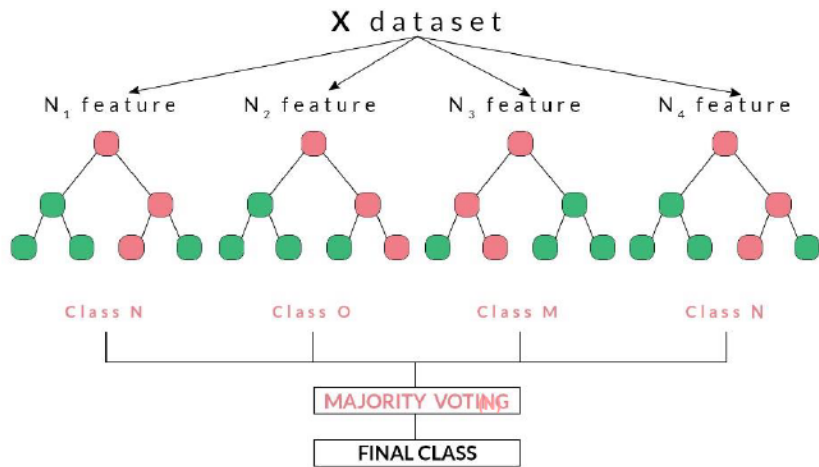
algoritmos



Tree Classifiers:

- Aprendizado Supervisionado;
- Regressão e Classificação;
- Nós;
- Relacionamento entre nós.

algoritmos



Random Forests:

- Múltiplas Árvores de Decisão;
- Regressão e Classificação;
- Melhores taxas de assertividade e maior custo computacional.

algoritmos




Figura 3 – SVM
Fonte: Gandhi, Rohith. Support Vector Machine – Introduction to ML Algorithms.

Support Vector Machines (SVM):

- Um dos mais preferidos de Data Scientists;
- Regressão e Classificação;
- Trade-off entre assertividade e custo computacional;
- Hiperplano Ótimo.

algoritmos





Figura 4 – Sampling

Fonte: <https://stats.stackexchange.com/questions/351638/random-sampling-methods-for-handling-class-imbalance>.

Sampling:

- Class Imbalance;
- Random Oversampling;
- Random Undersampling.

algoritmos



- Majority class samples
- Minority class samples
- Synthetic samples

Figura 4 – Sampling

Fonte: <https://stats.stackexchange.com/questions/351638/random-sampling-methods-for-handling-class-imbalance>.

Synthetic Minority Oversampling Technique (SMOTE):

- k-nn;
- Oversampling;
- Novos Registros.

método

Organização dos Tópicos:

- Aquisição de dados;
- Pré-processamento;
- Overfitting e Falsos Negativos;
- Otimização dos datasets;
- Benchmarking dos preditores.



método

Headers	Explicação	Exemplo
<i>step:</i>	Unidade de tempo. 1 <i>step</i> equivale à 1 hora.	1
<i>type:</i>	Tipo de transação.	PAYMENT
<i>amount:</i>	Unidade monetária. Valor total da transação.	1060.31
<i>nameOrig:</i>	ID da conta que iniciou a transação.	C429214117
<i>oldBalanceOrig:</i>	Balanço inicial antes a transação - conta de origem.	1089.0
<i>newBalanceOrig:</i>	Balanço final após a transação - conta de origem.	28.69
<i>nameDest:</i>	ID da conta que recebeu a transação.	M1591654462
<i>oldBalanceDest:</i>	Balanço inicial antes a transação - conta de destino.	0.0
<i>newBalanceDest:</i>	Balanço final após a transação - conta de destino.	0.0
<i>isFraud:</i>	A transação é uma fraude?	0
<i>isFlaggedFraud:</i>	A transação foi marcada como fraude pelo sistema da NTNU?	0

Base de Dados:

- Página do Kaggle da **Nowergian University of Science and Technology (NTNU)**;
- Synthetic Financial Datasets for Fraud Detection;
- Diminuída 4 vezes do tamanho original;
- 31 dias de transações;
- 11 Atributos;
- 6.354.407 Registros

método

Exemplo Original – <i>type(string)</i>	Conversão – <i>type(int)</i>
<i>Cash_In</i>	0
<i>Cash_Out</i>	1
<i>Debit</i>	2
<i>Payment</i>	3
<i>Transfer</i>	4

Tabela 2 – Variável *type*
Fonte: Autor

	fraud_proportion	non_fraud_proportion	fraud_examples	non_fraud_examples	total
sample					
train	0.001291	0.998709	6570	5083525	5090095
test	0.001292	0.998708	822	635442	636264
validation	0.001290	0.998710	821	635440	636261

Tabela 3 – Divisão do *dataset*
Fonte: Autor

Pré-processamento:

- Preparação, Organização e Estruturação dos dados;
- Limpeza e Normalização;
- Atributos Utilizados: 'isFraud', 'type', 'amount', 'oldBalanceOrig', 'newBalanceOrig', 'oldBalanceDest' e 'newBalanceDest';
- Divisão em 4 sub-datasets (**Training, Tests, Validation e Fraud**).

método

	train	test	validation	fraud	training time
tree classifier	0.999	0.999	0.999	0.041	0:00:05.459905
random forest	1.000	1.000	1.000	0.595	0:07:41.670989
svm	0.999	0.999	0.999	0.365	0:03:38.943760

Tabela 4 – Taxas de Assertividade
Fonte: Autor

Tree Classifier											
train			test			validation			fraud		
	Non-Fraud	Fraud		Non-Fraud	Fraud		Non-Fraud	Fraud		Non-Fraud	Fraud
Non-Fraud	5,083,511	0	Non-Fraud	635,437	0	Non-Fraud	635,459	0	Non-Fraud	0	0
Fraud	6,314	271	Fraud	794	31	Fraud	766	31	Fraud	1,575	68

Random Forests											
train			test			validation			fraud		
	Non-Fraud	Fraud		Non-Fraud	Fraud		Non-Fraud	Fraud		Non-Fraud	Fraud
Non-Fraud	5,083,511	0	Non-Fraud	634,430	7	Non-Fraud	635,450	9	Non-Fraud	0	0
Fraud	0	6,585	Fraud	19	656	Fraud	154	649	Fraud	664	979

SVM											
train			test			validation			fraud		
	Non-Fraud	Fraud		Non-Fraud	Fraud		Non-Fraud	Fraud		Non-Fraud	Fraud
Non-Fraud	5,083,406	105	Non-Fraud	635,422	15	Non-Fraud	635,451	8	Non-Fraud	0	0
Fraud	537	2,375	Fraud	537	288	Fraud	499	304	Fraud	1,044	599

Tabela 5 – Matrizes de Confusão
Fonte: Autor

Overfitting e Falsos Negativos:

- Altas taxas de assertividade no dataset de treinamento, teste e validação;
- Distorção;
- Falsos Negativos.

método

	fraud	training time	fraud	training time
tree classifier	0.041	0:00:05.459905	0.719	0:02:41.971565
random forest	0.595	0:07:41.670989	0.743	0:27:33.624551
svm	0.365	0:03:38.943760	0.730	0:24:56.213468

Tabela 6 – Assertividade no *dataset fraud* normalizado com ROS
Fonte: Autor

Random Oversampling:

- Duplicar registros da classe minoritária;

método

	fraud	training time	fraud	training time
tree classifier	0.041	0:00:05.459905	0.821	0:02:33.888025
random forest	0.595	0:07:41.670989	0.847	0:31:12.724637
svm	0.365	0:03:38.943760	0.834	0:28:47.734978

Tabela 7 – Assertividade no *dataset fraud* normalizado com SMOTE
Fonte: Autor

SMOTE:

- Novos registros gerados para a classe minoritária;

método

Tree Classifier - validation			
Imbalanced	Non-Fraud	Non-Fraud	Fraud
	Fraud	635,459	0
ROS	Non-Fraud	766	31
	Fraud	635,102	357
SMOTe	Non-Fraud	239	654
	Fraud	635,152	307

SVM - validation			
Imbalanced	Non-Fraud	Non-Fraud	Fraud
	Fraud	635,459	0
ROS	Non-Fraud	766	31
	Fraud	635,102	357
SMOTe	Non-Fraud	239	654
	Fraud	635,152	307

Random Forest - validation			
Imbalanced	Non-Fraud	Non-Fraud	Fraud
	Fraud	635,437	0
ROS	Non-Fraud	794	31
	Fraud	635,202	280
SMOTe	Non-Fraud	183	597
	Fraud	635,222	260

Tabela 7 – Matrizes de Confusão
Fonte: Autor

Benchmarking:

- Aumento das taxas de assertividade;
- Diminuição dos Falsos Negativos.

método

		train	test	validation	fraud
tree classifier	ROS	0.10%	0.00%	0.00%	94.30%
	SMOTe	0.10%	0.10%	0.00%	95.01%
random forest	ROS	0.00%	-0.10%	-0.10%	19.92%
	SMOTe	0.00%	-0.10%	-0.10%	29.75%
svm	ROS	0.10%	0.00%	0.00%	50.00%
	SMOTe	-9.06%	-3.42%	-3.42%	56.24%

Tabela 8 – Comparativos das taxas de assertividade com *datasets balanceados*
Fonte: Autor

Benchmarking:

- Comparativo das taxas de assertividade;

futuro

Sugestões Futuras:

- ADASYN;
- Comparar com o preditor da **NTNU**;
- Balancear o dataset de treinamento por uma GAN.



obrigado

Bruno Paes

Fernando Sinigaglia

Guilherme Heitzmann

Leonardo Briotto

Leonardo Messias

